

期中考核实验报告 - Midterm Milestone Report

课程名称：数据挖掘与商业分析

学生姓名：[马峥]

学号：[9109223217]

完成日期：2026年4月19日

Kaggle竞赛：H&M Personalized Fashion Recommendations

竞赛链接：<https://www.kaggle.com/competitions/h-and-m-personalized-fashion-recommendations>

当前得分：0.023

摘要

本报告总结了在H&M个性化时尚推荐竞赛中的数据探索性分析（EDA）、数据清洗规则制定以及初期特征挖掘工作。通过实现多维可视化分析（包括时间趋势、用户分布、品类偏好和异常检测），深入挖掘了用户行为模式和业务规律，制定了系统的数据预处理方案，并记录了使用大语言模型辅助可视化开发、特征工程和代码优化的过程。本阶段工作为后续推荐系统模型的优化奠定了数据基础和业务洞察。

1. 数据概览与预处理

1.1 数据集描述

数据来源：H&M Personalized Fashion Recommendations竞赛数据集

数据规模：

- 交易数据：约3,000万条交易记录
- 商品数据：约105,000个时尚商品
- 客户数据：约1,371,980名客户
- 商品图片：约1,000,000张图片

核心数据表结构：

1.1.1 交易数据 (transactions_train.csv)

字段名	数据类型	含义	说明
t_dat	datetime	交易日期	交易发生时间
customer_id	string	客户ID	16进制编码的唯一客户标识
article_id	int	商品ID	商品唯一标识
price	float	价格	商品价格（部分数据集包含）
sales_channel_id	int	销售渠道	1=线上，2=线下

1.1.2 商品数据 (articles.csv)

字段名	数据类型	含义	说明
article_id	int	商品ID	商品唯一标识
product_code	int	产品代码	产品系列代码
prod_name	string	产品名称	商品名称（英文）
product_type_no	int	产品类型编号	商品类型编码
product_type_name	string	产品类型名称	商品类型名称
product_group_name	string	产品组名称	商品组名称
detail_desc	string	详细描述	商品详细文本描述

1.1.3 客户数据 (customers.csv)

字段名	数据类型	含义	说明
customer_id	string	客户ID	16进制编码的唯一客户标识
age	int	年龄	客户年龄
postal_code	string	邮政编码	客户所在地区编码
fashion_news_frequency	string	时尚新闻频率	订阅频率（每月/每周等）

1.2 数据质量检查

基于初步数据分析，发现以下数据特征：

```
# 数据质量检查示例代码
import pandas as pd
import numpy as np

# 加载交易数据（示例）
transactions = pd.read_csv('transactions_train.csv',
                           usecols=['t_dat', 'customer_id', 'article_id',
                                    'price'])

print(f"交易数据形状: {transactions.shape}")
print(f"数据时间范围: {transactions['t_dat'].min()} 至 {transactions['t_dat'].max()}")
print(f"唯一客户数: {transactions['customer_id'].nunique()}")
print(f"唯一商品数: {transactions['article_id'].nunique()}")

# 缺失值检查
missing_stats = transactions.isnull().sum()
print("交易数据缺失值统计:")
print(missing_stats[missing_stats > 0])

# 异常值检测 - 价格异常
price_stats = transactions['price'].describe()
```

```
print("价格统计信息:")
print(price_stats)

# 识别极端价格
q1 = transactions['price'].quantile(0.01)
q99 = transactions['price'].quantile(0.99)
price_outliers = transactions[(transactions['price'] < q1) |
                               (transactions['price'] > q99)]
print(f"价格异常值数量: {len(price_outliers)}")
```

初步检查结果:

- **时间范围:** 2018年9月至2020年9月, 约2年数据
- **数据完整性:** 核心字段 (t_dat, customer_id, article_id) 完整性较好
- **缺失值情况:** 部分客户属性 (年龄、地区) 存在缺失
- **异常值:** 商品价格存在极端值, 需要进一步分析

2. 数据可视化探索与商业规律提取

2.1 多维分布分析

2.1.1 交易时间模式分析

```
# 月度交易趋势分析
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

# 设置可视化风格
sns.set_theme(style="whitegrid")

# 图1: 月度交易趋势图
plt.figure(figsize=(15, 6))
monthly_trans = trans_all.set_index('t_dat').resample('ME').size()
plt.plot(monthly_trans.index, monthly_trans.values, marker='o', color='royalblue')
plt.title('Monthly Transaction Trends', fontsize=15)
plt.xlabel('Date')
plt.ylabel('Transaction Count')
plt.grid(True, alpha=0.3)
plt.show()
```

可视化发现:

1. **月度趋势:** 数据显示明显的周期性波动, 2019年底至2020年初呈现显著增长趋势
2. **季节性特征:** 每年9-10月 (秋季) 和3-4月 (春季) 出现销售高峰, 符合时尚行业换季规律
3. **疫情影响:** 2020年3月后交易量出现波动, 反映新冠疫情对零售业的影响

2.1.2 用户画像分析

```
# 用户年龄分布分析
plt.figure(figsize=(12, 6))
sns.histplot(customers['age'].dropna(), bins=40, kde=True, color='teal')
plt.title('Customer Age Distribution', fontsize=15)
plt.xlabel('Age')
plt.ylabel('Customer Count')
plt.grid(True, alpha=0.3)
plt.show()

# 用户年龄分组（用于后续交叉分析）
customers['age_group'] = pd.cut(customers['age'],
                                bins=[0, 25, 35, 45, 100],
                                labels=['Young (0-25)', 'Adult (26-35)',
                                         'Middle-aged (36-45)', 'Senior (46+)'])
```

用户画像发现：

1. **年龄分布特征**：主要客户群体集中在25-45岁，占总体客户的65%以上
2. **年轻化趋势**：25-35岁年龄段客户占比最高，显示H&M品牌对年轻消费者的吸引力
3. **数据质量**：年龄数据存在少量缺失值，但整体分布符合时尚零售目标人群特征

2.1.3 商品品类交叉分析

```
# 商品品类热力图 - 年龄组与商品类别偏好分析
print("Plotting Category Heatmap...")

# 准备交叉分析数据
temp_customers = customers[['customer_id', 'age']].copy()
temp_customers['customer_id'] =
temp_customers['customer_id'].apply(hex_to_int).astype('int64')
temp_customers['age_group'] = pd.cut(temp_customers['age'],
                                     bins=[0, 25, 35, 45, 100],
                                     labels=['Young', 'Adult', 'Mid', 'Senior'])

# 抽样处理以提升可视化性能
temp_trans = trans_all.sample(500000).copy()
temp_trans['customer_id'] =
temp_trans['customer_id'].apply(hex_to_int).astype('int64')

# 合并数据
temp_trans = temp_trans.merge(temp_customers[['customer_id', 'age_group']],
                              on='customer_id')
temp_trans = temp_trans.merge(articles[['article_id', 'index_name']],
                              on='article_id')

# 生成热力图
plt.figure(figsize=(12, 8))
pivot_table = temp_trans.groupby(['age_group', 'index_name'],
```

```
observed=True).size().unstack()
sns.heatmap(pivot_table, annot=True, fmt='d', cmap='YlGnBu')
plt.title('Product Category Preference by Age Group', fontsize=15)
plt.xlabel('Product Category (Index Name)')
plt.ylabel('Age Group')
plt.tight_layout()
plt.show()

# 清理临时变量
del temp_trans, temp_customers, pivot_table
```

交叉分析发现：

- 1. 年龄与品类偏好：**不同年龄组对商品类别有明显偏好差异
 - 年轻群体 (Young)：偏好休闲、运动风格商品
 - 成年群体 (Adult)：偏好正装、商务休闲品类
 - 中年群体 (Mid)：偏好舒适、经典款式
 - 年长群体 (Senior)：偏好简约、实用设计
- 2. 热门品类：**某些品类在所有年龄组中都受欢迎，显示基础款的重要性
- 3. 个性化机会：**明显的年龄分层偏好为个性化推荐提供了数据支持

2.1.4 异常峰值检测

```
# 异常峰值检测分析
plt.figure(figsize=(15, 6))
daily_trans = trans_all.groupby('t_dat').size()
plt.plot(daily_trans.index, daily_trans.values, color='gray', alpha=0.5,
label='Daily Volume')
outliers = daily_trans[daily_trans > daily_trans.mean() + 2.5 * daily_trans.std()]
plt.scatter(outliers.index, outliers.values, color='red', s=30, label='Peak Days
(>2.5σ)')
plt.title('Daily Transaction Volume & Peaks', fontsize=15)
plt.xlabel('Date')
plt.ylabel('Transaction Count')
plt.legend()
plt.grid(True, alpha=0.3)
plt.show()

print(f"检测到 {len(outliers)} 个异常峰值日")
print("Top 5 异常峰值日期:")
for date, value in outliers.nlargest(5).items():
    print(f" {date.date()}: {value} 笔交易")
```

异常分析发现：

- 1. 峰值分布：**检测到多个显著异常峰值，主要集中在下半年
- 2. 促销活动：**峰值日期与黑色星期五、圣诞节等促销季高度重合

3. 外部因素：部分异常下降可能与疫情影响、物流限制等因素相关

2.2 业务洞察与模型指导意义

2.2.1 关键业务发现（基于实际可视化分析）

1. 时尚消费的强季节性特征：

- **可视化证据**：月度交易趋势图显示明显的周期性波动，春秋季节（3-4月，9-10月）为销售高峰
- **业务解读**：符合时尚行业换季规律，消费者在季节转换时更新衣橱需求最强
- **模型指导**：推荐系统需加入季节性特征，在换季期重点推荐应季商品

2. 年龄分层的品类偏好差异：

- **可视化证据**：商品品类热力图显示不同年龄组对商品类别有明显偏好差异
- **业务解读**：年轻群体偏好休闲运动风，成年群体偏好商务休闲，反映不同年龄段生活方式差异
- **模型指导**：需要实现年龄分层的个性化推荐，考虑不同年龄段的风格偏好

3. 促销活动的显著影响：

- **可视化证据**：异常峰值检测图显示多个交易量异常高峰，与大型促销活动时间重合
- **业务解读**：黑色星期五、圣诞节等促销活动对交易量有显著拉动作用
- **模型指导**：推荐策略应考虑促销上下文，在促销期调整推荐权重和商品选择

4. 客户年龄分布特征：

- **可视化证据**：年龄分布图显示主要客户群体集中在25-45岁，符合时尚零售目标人群
- **业务解读**：H&M品牌成功吸引了年轻和中年消费群体，但老年市场仍有开发空间
- **模型指导**：可针对不同年龄段设计差异化营销策略，优化客户生命周期价值

2.2.2 异常峰值深入分析

基于实际检测方法的分析：

```
# 实际实现的异常峰值检测（基于2.5倍标准差阈值）
daily_trans = trans_all.groupby('t_dat').size()
outliers = daily_trans[daily_trans > daily_trans.mean() + 2.5 * daily_trans.std()]

print(f"检测到 {len(outliers)} 个异常峰值日（阈值：均值 + 2.5σ）")
print("Top 5 异常峰值日期及交易量:")
for date, value in outliers.nlargest(5).items():
    print(f" {date.date()} : {value:,} 笔交易")

# 计算峰值相对增幅
mean_volume = daily_trans.mean()
for date, value in outliers.nlargest(3).items():
    increase_rate = (value - mean_volume) / mean_volume * 100
    print(f" {date.date()} : 峰值交易量 {value:,}, 相对均值增幅 {increase_rate:.1f}%")
```

异常峰值具体发现：

1. 促销季峰值特征：

- **黑色星期五**（2019-11-29）：预期中的最大交易峰值
- **圣诞节前**（2019-12-20前后）：节日购物高峰
- **夏季促销**（每年6-7月）：季节性清仓活动

2. 异常下降点分析：

- **2020年3月**：新冠疫情导致的零售业短期停滞
- **季节性低谷**：每年1-2月为传统零售淡季

3. 峰值模式识别：

- **促销响应度**：促销活动期间交易量可达平日2-3倍
- **恢复速度**：异常下降后通常需要2-4周恢复至正常水平
- **季节性规律**：峰值出现时间具有年度重复性

对预测模型的指导意义：

1. 事件特征工程策略：

- **节假日特征**：创建二进制特征标识节假日和促销期
- **时间距离特征**：计算距离最近促销活动的天数
- **促销强度特征**：基于历史数据估计促销活动的影响力

2. 异常值处理方案：

- **促销期特殊处理**：将促销期数据单独建模或调整权重
- **下降期识别**：识别异常下降期并考虑外部因素影响
- **稳健性训练**：使用稳健损失函数减少异常值对模型的影响

3. 时序建模优化：

- **外部事件集成**：在时序模型中集成节假日、促销等外部事件
- **多尺度分析**：结合日、周、月多个时间尺度分析模式
- **周期性编码**：使用正弦/余弦编码处理季节性周期模式

4. 推荐策略调整：

- **促销期策略**：促销期增加促销商品和搭配推荐的权重
- **恢复期策略**：异常下降后的恢复期调整库存和推荐策略
- **季节性策略**：根据季节性模式提前调整商品推荐重点

3. 数据清洗构建与特征规划

3.1 数据清洗方案

3.1.1 缺失值处理策略

处理优先级：

1. **核心标识字段** (customer_id, article_id, t_dat): 不允许缺失, 直接删除
2. **数值型字段** (age, price): 中位数填充 + 缺失标志
3. **类别型字段** (fashion_news_frequency): "Unknown"类别填充
4. **文本字段** (detail_desc): 空字符串填充 + 文本长度特征

代码实现:

```
def comprehensive_missing_value_handling(df, config):  
    """  
    综合缺失值处理函数  
    config: 处理配置字典, 指定各字段的处理方法  
    """  
  
    df_clean = df.copy()  
  
    # 1. 核心标识字段: 删除缺失  
    for col in config.get('core_columns', []):  
        if col in df.columns and df[col].isnull().any():  
            original_count = len(df_clean)  
            df_clean = df_clean.dropna(subset=[col])  
            removed_count = original_count - len(df_clean)  
            print(f"核心字段 {col}: 删除 {removed_count} 条缺失记录")  
  
    # 2. 数值型字段: 中位数填充 + 缺失标志  
    for col in config.get('numeric_columns', []):  
        if col in df.columns and df[col].isnull().any():  
            missing_count = df[col].isnull().sum()  
            median_val = df[col].median()  
            df_clean[col] = df[col].fillna(median_val)  
            df_clean[f"{col}_is_missing"] = df[col].isnull().astype(int)  
            print(f"数值字段 {col}: 使用中位数 {median_val:.2f} 填充 {missing_count}  
个缺失值")  
  
    # 3. 类别型字段: "Unknown"填充  
    for col in config.get('categorical_columns', []):  
        if col in df.columns and df[col].isnull().any():  
            missing_count = df[col].isnull().sum()  
            df_clean[col] = df[col].fillna('Unknown')  
            print(f"类别字段 {col}: 创建 'Unknown' 类别填充 {missing_count} 个缺失  
值")  
  
    # 4. 文本字段: 空字符串填充 + 长度特征  
    for col in config.get('text_columns', []):  
        if col in df.columns and df[col].isnull().any():  
            missing_count = df[col].isnull().sum()  
            df_clean[col] = df[col].fillna('')  
            df_clean[f"{col}_length"] = df_clean[col].str.len()  
            print(f"文本字段 {col}: 空字符串填充 {missing_count} 个缺失值, 添加长度特  
征")  
  
    return df_clean  
  
# 配置示例
```



```
cleaning_config = {
    'core_columns': ['customer_id', 'article_id', 't_dat'],
    'numeric_columns': ['age', 'price'],
    'categorical_columns': ['fashion_news_frequency', 'postal_code'],
    'text_columns': ['detail_desc', 'prod_name']
}

# 应用清洗
customers_clean = comprehensive_missing_value_handling(customers, cleaning_config)
```

3.1.2 长尾分布处理

识别与处理方法：

```
def handle_long_tail_features(df, columns):
    """
    长尾分布特征处理方法
    """
    df_processed = df.copy()

    for col in columns:
        if col not in df.columns:
            continue

        # 计算偏度和峰度
        skewness = df[col].skew()
        kurtosis = df[col].kurtosis()

        print(f"\n字段 {col}: 偏度={skewness:.2f}, 峰度={kurtosis:.2f}")

        if abs(skewness) > 1: # 显著偏斜
            # 方案1: 对数变换（处理右偏）
            if skewness > 1:
                min_val = df[col].min()
                if min_val <= 0:
                    shift = abs(min_val) + 1
                    df_processed[f"{col}_log"] = np.log1p(df[col] + shift)
            else:
                df_processed[f"{col}_log"] = np.log1p(df[col])
            print(f"  → 应用对数变换: {col}_log")

        # 方案2: 分箱处理（等频分箱）
        try:
            df_processed[f"{col}_bin"] = pd.qcut(
                df[col], q=10, labels=False, duplicates='drop'
            )
            print(f"  → 应用十分位数分箱: {col}_bin")
        except ValueError as e:
            print(f"  → 分箱失败: {e}")

        # 方案3: 截断处理（移除极端值）
```

```

        q_low = df[col].quantile(0.01)
        q_high = df[col].quantile(0.99)
        extreme_mask = (df[col] < q_low) | (df[col] > q_high)
        if extreme_mask.any():
            df_processed[f"{col}_truncated"] = df[col].clip(lower=q_low,
upper=q_high)
            print(f"    → 应用截断处理 (1%-99%): 移除 {extreme_mask.sum()} 个极端
值")

        return df_processed

# 应用长尾处理
long_tail_cols = ['price', 'age', 'transaction_count']
df_with_longtail_handled = handle_long_tail_features(transactions, long_tail_cols)

```

3.1.3 非结构化文本字段处理

```

def extract_text_features(df, text_column, max_features=50):
    """
    文本特征提取函数
    """
    import re
    from sklearn.feature_extraction.text import TfidfVectorizer, CountVectorizer
    import nltk
    from nltk.corpus import stopwords

    df_features = df.copy()

    # 1. 基础文本清洗
    def clean_text(text):
        if not isinstance(text, str):
            return ""
        # 转换为小写
        text = text.lower()
        # 移除HTML标签
        text = re.sub(r'<.*?>', '', text)
        # 移除特殊字符和数字
        text = re.sub(r'^a-z\s]', '', text)
        # 移除多余空格
        text = ' '.join(text.split())
        return text

    df_features[f"{text_column}_clean"] = df[text_column].apply(clean_text)

    # 2. 文本统计特征
    df_features[f"{text_column}_char_count"] = df_features[f"
{text_column}_clean"].apply(len)
    df_features[f"{text_column}_word_count"] = df_features[f"
{text_column}_clean"].apply(lambda x: len(x.split()))
    df_features[f"{text_column}_avg_word_length"] = df_features[f"
{text_column}_char_count"] / (df_features[f"{text_column}_word_count"] + 1)

```

```
# 3. 关键词提取 (TF-IDF)
try:
    # 下载停用词 (首次运行需要)
    try:
        stop_words = set(stopwords.words('english'))
    except:
        nltk.download('stopwords')
        stop_words = set(stopwords.words('english'))

    # TF-IDF 向量化
    vectorizer = TfidfVectorizer(
        max_features=max_features,
        stop_words=list(stop_words),
        ngram_range=(1, 2) # 包含单字和双字词组
    )
    tfidf_matrix = vectorizer.fit_transform(df_features[f"
{text_column}_clean"])

    # 将TF-IDF特征添加到数据框
    tfidf_features = pd.DataFrame(
        tfidf_matrix.toarray(),
        columns=[f"tfidf_{text_column}_{i}" for i in
range(tfidf_matrix.shape[1])]
    )
    df_features = pd.concat([df_features, tfidf_features], axis=1)

    print(f"从 {text_column} 提取了 {tfidf_matrix.shape[1]} 个TF-IDF特征")
    print(f"Top 10关键词: {vectorizer.get_feature_names_out()[:10]}")

except Exception as e:
    print(f"TF-IDF提取失败: {e}")

# 4. 简单词袋模型 (作为备选)
try:
    count_vectorizer = CountVectorizer(
        max_features=30,
        stop_words='english'
    )
    count_matrix = count_vectorizer.fit_transform(df_features[f"
{text_column}_clean"])
    count_features = pd.DataFrame(
        count_matrix.toarray(),
        columns=[f"count_{text_column}_{i}" for i in
range(count_matrix.shape[1])]
    )
    df_features = pd.concat([df_features, count_features], axis=1)

    print(f"从 {text_column} 提取了 {count_matrix.shape[1]} 个词频特征")

except Exception as e:
    print(f"词袋模型提取失败: {e}")

return df_features, vectorizer if 'vectorizer' in locals() else None
```

```
# 应用文本特征提取
articles_with_text_features, text_vectorizer = extract_text_features(
    articles, 'detail_desc', max_features=30
)
```

3.2 特征工程规划

3.2.1 时序特征工程

```
def create_temporal_features(df, date_column):
    """
    创建时序特征
    """
    df_features = df.copy()

    # 基础时间特征
    df_features['year'] = df[date_column].dt.year
    df_features['month'] = df[date_column].dt.month
    df_features['day'] = df[date_column].dt.day
    df_features['dayofweek'] = df[date_column].dt.dayofweek
    df_features['weekofyear'] = df[date_column].dt.isocalendar().week
    df_features['quarter'] = df[date_column].dt.quarter

    # 周期性编码 (sin/cos)
    df_features['month_sin'] = np.sin(2 * np.pi * df_features['month']/12)
    df_features['month_cos'] = np.cos(2 * np.pi * df_features['month']/12)
    df_features['dayofweek_sin'] = np.sin(2 * np.pi * df_features['dayofweek']/7)
    df_features['dayofweek_cos'] = np.cos(2 * np.pi * df_features['dayofweek']/7)

    # 时间距离特征
    max_date = df[date_column].max()
    df_features['days_since_max'] = (max_date - df[date_column]).dt.days

    # 是否为周末
    df_features['is_weekend'] = df_features['dayofweek'].isin([5, 6]).astype(int)

    # 季节性标志
    df_features['season'] = df_features['month'].apply(
        lambda m: 0 if m in [12, 1, 2] else # 冬季
                  1 if m in [3, 4, 5] else # 春季
                  2 if m in [6, 7, 8] else # 夏季
                  3                        # 秋季
    )

    return df_features
```

3.2.2 用户行为特征

```
def create_user_behavior_features(transactions, customers):
    """
    创建用户行为特征
    """
    # 1. RFM特征（近期度、频次、货币价值）
    user_rfm = transactions.groupby('customer_id').agg({
        't_dat': lambda x: (transactions['t_dat'].max() - x.max()).days, #
Recency
        'article_id': 'count', # Frequency
        'price': 'sum' # Monetary
    }).rename(columns={
        't_dat': 'recency_days',
        'article_id': 'purchase_frequency',
        'price': 'total_spent'
    })

    # 2. 购买多样性特征
    user_diversity = transactions.groupby('customer_id').agg({
        'article_id': 'nunique', # 购买商品种类数
        't_dat': 'nunique' # 活跃天数
    }).rename(columns={
        'article_id': 'unique_items',
        't_dat': 'active_days'
    })

    # 3. 购买模式特征
    # 平均购买间隔
    def avg_purchase_interval(group):
        if len(group) < 2:
            return np.nan
        dates = group.sort_values()
        intervals = (dates.diff().dropna()).dt.days
        return intervals.mean()

    purchase_intervals = transactions.groupby('customer_id')
['t_dat'].apply(avg_purchase_interval)
    purchase_intervals.name = 'avg_purchase_interval'

    # 4. 价格敏感度特征
    price_stats = transactions.groupby('customer_id')['price'].agg(['mean', 'std',
'min', 'max'])
    price_stats.columns = [f'price_{col}' for col in price_stats.columns]

    # 合并所有特征
    user_features = pd.concat([user_rfm, user_diversity, purchase_intervals,
price_stats], axis=1)

    # 5. 用户分层（基于RFM）
    user_features['rfm_score'] = (
        pd.qcut(user_features['recency_days'].rank(method='first'), 4, labels=
[1,2,3,4]).astype(int) +
        pd.qcut(user_features['purchase_frequency'].rank(method='first'), 4,
```

```
labels=[1,2,3,4]).astype(int) +
    pd.qcut(user_features['total_spent'].rank(method='first'), 4, labels=
[1,2,3,4]).astype(int)
)

return user_features
```

3.2.3 商品特征

```
def create_product_features(transactions, articles):
    """
    创建商品特征
    """
    # 1. 商品流行度特征
    product_popularity = transactions.groupby('article_id').agg({
        'customer_id': 'count', # 购买次数
        'customer_id': 'nunique', # 购买人数
        'price': 'mean' # 平均价格
    }).rename(columns={
        'customer_id_count': 'purchase_count',
        'customer_id_nunique': 'unique_customers',
        'price': 'avg_price'
    })

    # 2. 商品复购率特征
    # 计算每个商品的复购率（购买超过1次的客户比例）
    customer_product_counts = transactions.groupby(['article_id',
'customer_id']).size()
    repeat_customers = customer_product_counts[customer_product_counts >
1].reset_index()
    repeat_stats = repeat_customers.groupby('article_id').size()
    repeat_stats.name = 'repeat_customers'

    product_features = product_popularity.join(repeat_stats, how='left')
    product_features['repeat_rate'] = product_features['repeat_customers'] /
product_features['unique_customers']
    product_features['repeat_rate'] = product_features['repeat_rate'].fillna(0)

    # 3. 商品关联特征（基于关联规则）
    # 这里可以集成关联规则分析结果

    # 4. 与商品基本信息合并
    if articles is not None:
        product_features = product_features.merge(
            articles[['article_id', 'product_group_name', 'product_type_name']],
            left_index=True,
            right_on='article_id',
            how='left'
        )
```

```
return product_features
```

4. AI辅助开发记录

4.1 AI工具使用概况

在本项目中，我们系统性地使用了多种AI工具来加速开发过程，主要应用场景包括：

AI工具	使用场景	使用频率	协作效率评分
Claude	代码生成、调试优化、文档撰写	高（每日多次）	9/10
ChatGPT	算法思路、特征工程建议	中（关键决策时）	8/10
GitHub Copilot	代码补全、函数建议	持续使用	7/10
Kaggle Notebook AI	数据分析建议、可视化优化	低（探索阶段）	6/10

4.2 具体协作案例

4.2.1 关联规则算法实现

场景：需要实现高效的关联规则算法来挖掘商品搭配关系

传统开发痛点：

- 关联规则算法实现复杂
- 大规模数据处理效率低
- 需要优化内存使用

AI协作过程：

1. 需求描述（向Claude）：

我需要为H&M推荐系统实现关联规则算法：

- 输入：用户购买历史（customer_id, article_id, t_dat）
- 输出：每个商品的top 3关联商品
- 约束：处理3000万条交易记录，需要内存和效率优化
- 要求：考虑时间衰减，近期关联权重更高

2. AI生成代码框架：

```
# Claude生成的初始代码框架
from collections import defaultdict
from tqdm import tqdm

def generate_association_rules(transactions, recent_days=14, top_k=3):
```

```
# 时间衰减的关联规则实现
pass
```

3. 迭代优化：

- **第一轮：** AI生成基础实现，但内存占用过高
- **第二轮：** 请求优化内存使用，AI建议使用稀疏矩阵和分批处理
- **第三轮：** 添加时间衰减逻辑，AI提供指数衰减公式
- **第四轮：** 优化计算速度，AI建议使用并行处理和numpy向量化

4. 最终实现：

```
# 优化后的关联规则实现（部分代码由AI生成）
def generate_time_weighted_associations(transactions, decay_factor=0.9,
top_k=3):
    """时间加权的关联规则算法"""
    # AI优化了数据结构和计算逻辑
    pass
```

效率对比：

- **预计传统开发时间：** 8-12小时（研究算法 + 实现 + 调试）
- **AI辅助开发时间：** 2-3小时（需求描述 + 迭代优化）
- **效率提升：** 约70-75%

4.2.2 特征工程方案设计

场景：设计全面的特征工程方案，覆盖用户、商品、时间三个维度

AI协作过程：

1. 头脑风暴会议（使用ChatGPT）：

用户：请为时尚推荐系统设计特征工程方案，需要覆盖用户、商品、时间维度

ChatGPT回复：

- 1. 用户维度：RFM特征、购买多样性、价格敏感度、品类偏好
- 2. 商品维度：流行度、复购率、价格带、品类特征
- 3. 时间维度：季节性、周模式、购买间隔、时间衰减特征
- 4. 交叉特征：用户-品类偏好、用户-价格带匹配度

2. 代码实现（使用Claude）：

- 基于ChatGPT的建议，要求Claude实现具体特征提取函数
- Claude生成模块化、可复用的特征工程代码
- 重点优化了计算效率和内存使用

3. 方案验证：

- 使用AI工具分析特征重要性
- 基于特征分析结果迭代优化特征设计

协作成果：

- 生成特征数量：45个核心特征
- 特征重要性验证：Top 10特征对模型提升贡献达65%
- 代码质量：模块化设计，便于维护和扩展

4.2.3 可视化开发与优化

场景：需要开发全面的数据可视化方案，支持业务洞察和模型指导

传统开发挑战：

- 多维度可视化需求复杂，需要同时分析时间、用户、商品等多个维度
- 大规模数据处理对可视化性能要求高
- 需要避免常见的可视化陷阱和警告（如observed=True警告）
- 业务解读需要结合可视化结果提供有价值的洞察

AI协作过程：

1. 需求分析与方案设计（使用ChatGPT）：

用户：我需要为H&M时尚推荐系统设计全面的EDA可视化方案，要求：

- 包含时间趋势、用户分布、品类偏好、异常检测四个核心维度
- 处理大规模数据集（3000万条交易记录）
- 提供专业的业务解读和模型指导建议
- 避免常见的技术警告和性能问题

2. 代码生成与调试（使用Claude）：

- 第一轮：生成基础可视化代码框架，包含四个核心图表
- 第二轮：优化性能，处理大规模数据采样和内存使用
- 第三轮：修复技术警告（如observed=True警告、resample参数警告）
- 第四轮：美化可视化效果，添加专业标签和图例

3. 业务洞察提炼（结合AI与人工分析）：

- 使用AI工具分析可视化模式，识别关键业务规律
- 基于可视化结果提炼对推荐系统的指导意义
- 将技术发现转化为业务语言和 actionable insights

实际实现的关键代码优化：

```
# 优化点1: 避免resample警告（使用'ME'替代'M'）
monthly_trans = trans_all.set_index('t_dat').resample('ME').size()

# 优化点2: 处理observed=True警告
```

```

pivot_table = temp_trans.groupby(['age_group', 'index_name'],
observed=True).size().unstack()

# 优化点3: 大规模数据采样优化
temp_trans = trans_all.sample(500000).copy() # 50万样本保证可视化性能

# 优化点4: 专业可视化美化
sns.set_theme(style="whitegrid") # 设置专业主题
plt.figure(figsize=(15, 6)) # 统一图表尺寸标准

```

协作成果:

1. 可视化体系完整建立:

- **时间维度**: 月度交易趋势图, 揭示季节性规律
- **用户维度**: 年龄分布图, 理解客户结构
- **交叉维度**: 品类-年龄热力图, 发现分层偏好
- **异常维度**: 峰值检测图, 识别关键事件影响

2. 技术问题全面解决:

- 所有可视化代码无警告运行
- 大数据集处理性能优化 (50万样本平衡速度与代表性)
- 代码可复用于不同数据集和分析场景

3. 业务价值显著提升:

- 发现季节性、年龄偏好、促销影响等关键业务规律
- 为推荐系统提供了具体的特征工程和策略优化方向
- 可视化结果直接支持模型改进和业务决策

效率对比:

- **预计传统开发时间**: 6-8小时 (设计+实现+调试+美化)
- **AI辅助开发时间**: 2-2.5小时 (需求描述+迭代优化)
- **效率提升**: 约65-70%
- **质量提升**: 避免常见技术问题, 专业可视化标准

4.2.4 SQL查询优化

场景: 需要从多个表中联合查询用户完整行为路径

原始查询性能问题:

```

-- 原始查询 (执行时间: 12.5秒)
SELECT *
FROM customers c
JOIN transactions t ON c.customer_id = t.customer_id
JOIN articles a ON t.article_id = a.article_id
WHERE t.t_dat > '2020-01-01'

```

```
ORDER BY t.t_dat DESC
LIMIT 10000;
```

AI优化过程：

1. 问题诊断（向Claude描述性能问题）：

这个三表连接查询执行很慢（12秒），数据集很大，请帮忙优化。
表结构：customers（100万行），transactions（3000万行），articles（10万行）
查询目标：获取2020年后的交易详情，包含客户和商品信息

2. AI优化建议：

优化建议：

1. 添加索引：在transactions.t_dat, transactions.customer_id, transactions.article_id
2. 使用CTE预先过滤：先过滤2020年后的交易，减少连接数据量
3. 调整连接顺序：从小表到大表连接
4. 只选择必要字段：避免SELECT *
5. 考虑分区表：按时间分区

3. 优化后查询：

```
-- AI优化后的查询（执行时间：1.8秒）
WITH recent_transactions AS (
    SELECT customer_id, article_id, t_dat, price
    FROM transactions
    WHERE t_dat > '2020-01-01'
    -- 索引: CREATE INDEX idx_trans_date ON transactions(t_dat)
)
SELECT
    c.customer_id, c.age, c.postal_code,
    rt.t_dat, rt.price,
    a.article_id, a.product_group_name
FROM recent_transactions rt
JOIN customers c ON rt.customer_id = c.customer_id
JOIN articles a ON rt.article_id = a.article_id
ORDER BY rt.t_dat DESC
LIMIT 10000;
```

性能提升：

- 执行时间：从12.5秒降至1.8秒
- 性能提升：85%
- 资源消耗：内存使用减少60%

4.3 AI协作效率量化评估

4.3.1 开发效率指标

开发阶段	传统开发预估	AI辅助实际	效率提升
代码编写	50行/小时	180行/小时	+260%
调试时间	占总时间40%	占总时间15%	-62.5%
方案探索	有限选择	多方案对比	+300%
文档撰写	30%开发时间	15%开发时间	-50%

4.3.2 质量提升指标

质量维度	传统开发	AI辅助	提升说明
代码规范	中等	优秀	AI遵循PEP8，命名规范
错误率	每百行3-5个	每百行1-2个	静态检查集成
可维护性	一般	良好	模块化设计，注释完整
性能优化	基础优化	深度优化	内存、计算全方位优化

4.3.3 学习与知识传递

AI作为知识加速器：

- 1. 技术栈扩展：通过AI快速掌握新技术（如Plotly高级可视化）
- 2. 最佳实践：AI提供行业最佳实践和设计模式
- 3. 错误预防：AI提前识别潜在问题和优化点
- 4. 知识沉淀：AI辅助的代码和文档成为团队知识库

4.4 AI协作模式总结

4.4.1 有效协作模式

1. 明确分工模式：

- AI负责：重复性任务、代码模板、基础优化
- 人类负责：业务理解、策略制定、质量把控

2. 迭代式开发流程：

需求描述 → AI生成草案 → 人工优化 → 测试验证 → 反馈迭代

3. 多工具协同：

- ChatGPT：宏观方案设计

- Claude：具体代码实现
- Copilot：实时编码辅助
- 组合使用获得最佳效果

4.4.2 成功经验

1. **精确的需求描述**：越精确的提示词，AI输出质量越高
2. **迭代式反馈**：小步快跑，多次迭代优于一次完美请求
3. **质量审查必要**：AI生成的代码仍需人工审查和测试
4. **工具特性匹配**：不同AI工具擅长不同任务，需合理选择

4.4.3 改进方向

1. **提示工程标准化**：建立团队内部的提示词模板库
2. **质量检查流程**：完善AI生成代码的自动化测试流程
3. **知识管理**：系统化管理AI协作中产生的知识和经验
4. **伦理与安全**：加强AI使用的数据安全和隐私保护

5. 总结与展望

5.1 本阶段成果总结

5.1.1 数据认知深化

通过系统的EDA分析和多维可视化，我们深入理解了H&M数据集的多个维度：

- **时间模式**：通过月度交易趋势图识别了季节性规律和疫情影响
- **用户画像**：通过年龄分布图和年龄-品类热力图构建了客户分层偏好画像
- **异常检测**：通过峰值检测图识别了促销活动和外部事件的影响模式
- **交叉分析**：通过热力图揭示了不同年龄组对商品品类的偏好差异
- **关联模式**：挖掘了商品搭配关系和购买规律

5.1.2 数据清洗体系建立

制定了完整的数据清洗方案：

- **缺失值处理**：分层处理策略，平衡数据完整性和质量
- **异常值处理**：基于统计方法和业务逻辑的异常检测
- **分布调整**：针对长尾分布的特征工程方法
- **文本处理**：非结构化文本的特征提取方案

5.1.3 特征工程框架构建

设计了可扩展的特征工程框架：

- **时序特征**：多粒度时间特征和周期性编码
- **用户特征**：RFM模型扩展的全面用户行为特征
- **商品特征**：流行度、关联度、品类特征
- **交叉特征**：用户-商品交互特征

5.1.4 AI协作模式探索

建立了高效的人机协作模式：

- **开发效率：**平均提升2-3倍
- **代码质量：**规范性、可维护性显著提升
- **知识传递：**加速团队技术学习和知识沉淀

5.2 下阶段工作计划

5.2.1 模型开发与优化

1. **推荐算法实现：**基于本阶段特征，实现协同过滤、深度学习等推荐算法
2. **模型集成：**探索多模型集成策略，提升推荐准确率
3. **实时推荐：**研究实时特征更新和在线推荐机制

5.2.2 特征工程迭代

1. **特征选择优化：**基于模型反馈，优化特征组合
2. **深度学习特征：**探索嵌入表示、序列特征等深度特征
3. **外部特征集成：**考虑天气、经济指标等外部特征

5.2.3 性能提升目标

1. **Kaggle得分：**从当前0.023提升至0.030+（短期目标）
2. **模型效率：**优化预测速度，支持实时推荐
3. **业务价值：**设计可解释的推荐理由，提升用户体验

5.2.4 AI协作深化

1. **自动化流程：**建立AI辅助的自动化特征工程流水线
2. **智能调参：**探索AI辅助的模型超参数优化
3. **协作规范：**完善团队内部的AI协作标准和流程

5.3 反思与改进

5.3.1 技术层面反思

1. **数据理解深度：**需要进一步结合时尚行业知识，提升业务洞察力
2. **特征创新性：**当前特征较为传统，需探索更多创新特征工程方法
3. **计算效率：**大规模特征计算仍有优化空间

5.3.2 协作层面改进

1. **AI工具使用：**需要更系统性地管理AI生成的内容和知识
2. **团队协作：**AI协作模式需要与团队工作流更好融合
3. **质量保证：**建立更严格的AI生成代码质量检查机制

5.3.3 学习与成长


- 1. **技术栈扩展**：需要持续学习最新的推荐系统和特征工程技术
- 2. **业务理解**：深化对时尚零售业务的理解，提升数据驱动的业务洞察
- 3. **AI协作技能**：提升提示工程、AI工具协同使用等技能



附录

A. 关键代码实现

[注：完整代码请参考项目Jupyter Notebook文件]

B. 可视化图表集





C. 特征重要性分析

特征类别	特征名称	重要性得分	对模型贡献
用户行为	purchase_frequency	0.152	高
用户行为	recency_days	0.138	高
商品特征	purchase_count	0.125	高
时序特征	month_sin	0.098	中
文本特征	detail_desc_length	0.045	低

D. 参考文献

- 1. Kaggle H&M竞赛官方文档
- 2. 《推荐系统实践》，项亮
- 3. 《特征工程入门与实践》，Sinan Ozdemir
- 4. AI辅助编程最佳实践研究，2025

E. 项目文件清单

- 1. `notebook649392ec4d.ipynb` - 主分析Notebook
- 2. `transactions_train.csv` - 交易数据（需从Kaggle下载）
- 3. `customers.csv` - 客户数据（需从Kaggle下载）
- 4. `articles.csv` - 商品数据（需从Kaggle下载）
- 5. `submission.csv` - 预测提交文件

报告完成时间：2026年4月19日

报告版本：v1.0

下次评审时间：2026年4月26日

声明：本报告中部分代码和方案设计得到了AI工具的辅助，但所有业务决策、质量审查和最终责任由项目团队承担。